



# Steam 게임 리뷰 감성 분석 대시보드


리뷰를 입력하면 긍정·부정을 자동으로 분류하는 머신러닝 웹앱

발표자 : 김유진

## ● 주제 & 목표

게임 전체 리뷰는 너무 많아 일일이 읽기 어렵다.

게임들의 리뷰의 긍정 / 부정을 자동으로 분류해 한눈에 파악하는 것이 목표.



## ● 문제 해결 과정

### ① 데이터가 부족했다

문제

OpenCritic API로 시작 → 무료 요청량·  
데이터 제공량이 한정적 (표본 부족, 평론 위주)



해결

Steam 공개 리뷰로 데이터 수집

### ② 수집이 한쪽으로 치우쳤다

문제

여러 주제를 모으려는데 한 주제의 게임을 끝까지  
수집해야 다음 주제를 수집



해결

라운드 로빈 도입 → 주제당 게임 N개씩  
받고 교대 → 지정된 주제들 내에서 고르게  
수집

## ● 데이터 수집

# 260만+

학습에 사용한 Steam 한국어 리뷰

```
{"game": "...", "review": "...", "voted_up": true}
```

※ 문제를 늦게 해결해 자체 수집 데이터가 부족했습니다.  
그래서 학습에는 같은 주제를 조사한 다른 학생의 수집 데이터(260만 건)를 사용했습니다.

### 6개 장르

RPG · 어드벤처 · 인디 · 시뮬 · 스포츠 · 인기

### 명확한 라벨

추천 = 긍정 / 비추천 = 부정

### 저장 형식

JSONL (게임 · 리뷰 · 평점)

# ● 전처리 방법

확보한 260만 건을 학습에 쓸 수 있게 정리하는 과정

- 1 **대용량 파일 한 줄씩 읽기**  
260만 건 JSONL을 메모리에 다 올리지 않고 스트리밍 처리
- 2 **텍스트 정제**  
BBCode·URL 제거, 한글 없는/너무 짧은 리뷰(잡음) 제거
- 3 **라벨 붙이기**  
추천 → 긍정(1) / 비추천 → 부정(0)
- 4 **클래스 균형 맞추기**  
긍정·부정 개수를 동일하게 추출

## 왜 균형을 맞췄나?

실제 데이터는 한쪽으로 치우침

긍정 175만

부정 33만 (약 5 : 1)

→ 그대로 학습하면 '긍정'만 잘 맞히는  
치우친 모델이 됨

각 2만 개씩 = 총 4만 개로  
균형 잡힌 학습 데이터 생성

# ● 모델 학습

한국어 형태소 분석(Okt) → TF-IDF 벡터화 → 로지스틱 회귀 학습

1

## 학습 / 평가 데이터 분리

균형 데이터 4만 건 → 학습 3.2만 · 평가 8천 (긍·부정 비율 유지해 분리)

2

## 한국어 토큰화 (Okt)

명사·형용사·동사만 추출 + 원형 복원 ('재밌어요' → '재밌다')

3

## 특징 벡터화 (TF-IDF)

학습셋 기준 상위 3,000개 단어를 중요도(가중치) 숫자로 변환

4

## 로지스틱 회귀 학습

변환된 벡터로 분류 모델 학습 (max\_iter=1000)

## 학습 결과

평가 데이터 8,000건 기준

**정확도 78%**

긍정·부정 정밀도·재현율  
모두 약 0.78 (한쪽 치우침 없음)

## 배포

벡터라이저·모델을 .pkl로 저장  
→ 대시보드에서 불러와 바로 예측

## ● 결과물 : 감성 분석 대시보드



## 긍정 리뷰 키워드



## 부정 리뷰 키워드

"그래픽은 좋은데 최적화가 너무 별로예요" → 부정 (89%)

## ● 마무리

### 성과

- 크롤링 → 전처리 → 학습 →
- 대시보드 전 과정 구현
- 분류 정확도 약 78%

### 한계

- 번역체·반어 표현에 약함
- 추천/비추천 이진 분류만
- 장르 데이터 불균형

### 향후 (~06/30)

- 게임별 리뷰 분류 분석 추가
- 번역체·반어 등에 대한 학습 처리 추가